Проект QA

Yes/No Questions

Вы будете работать с корпусом BoolQ. Корпус состоит из вопросов, предполагающих бинарный ответ (да / нет), абзацев из Википедии, содержащих ответ на вопрос, заголовка статьи, из которой извлечен абзац и непосредственно ответа (true / false).

Корпус описан в статье:

Christopher Clark, Kenton Lee, Ming-Wei Chang, Tom Kwiatkowski, Michael Collins, Kristina Toutanova BoolQ: Exploring the Surprising Difficulty of Natural Yes/No Questions

https://arxiv.org/abs/1905.10044 (https://arxiv.org/abs/1905.10044)

Kopпyc (train-dev split) доступен в репозитории проекта: https://github.com/google-research-datasets/boolean-questions)

Каждый бонус пункт оцениватся в 1 балл. Вывод является обязательным!

Пример вопроса:

question: is batman and robin a sequel to batman forever

title: Batman & Robin (film)

answer: true

passage: With the box office success of Batman Forever in June 1995, Warner Bros. immediately commissioned a sequel. They hired director Joel Schumacher and writer Akiva Goldsman to reprise their duties the following August, and decided it was best to fast track production for a June 1997 target release date, which is a break from the usual 3-year gap between films. Schumacher wanted to homage both the broad camp style of the 1960s television series and the work of Dick Sprang. The storyline of Batman & Robin was conceived by Schumacher and Goldsman during pre-production on A Time to Kill. Portions of Mr. Freeze's back-story were based on the Batman: The Animated Series episode "Heart of Ice", written by Paul Dini.

Соображения по методологии

Проведение одного эксперимента

- 1. Подбирайте гиперпараметры! Это довольно важно. Гиперпараметры --- это размеры слоёв, например. Хотя бы в одном эксперименте это стоит сделать честно, в остальных экспериментах в принципе можно предполагать, что в предыдущем эксперименте оптимальные размеры модели уже найдены.
- 2. Часто вам придётся скачивать предобученные веса (вроде BERT или RoBERTa) и дообучать дополнительные веса. В таком случае стоит попробовать несколько разных подходов:
- обучать только новые (головные) слои
- обучать совместно всю модель
- сначала обучить головные слои, потом дофайнтьюнить веса всей модели

- 3. Фиксируйте лучшие результаты на валидационной выборке, по валидационной же выборке останавливайте обучение
- 4. Графики, графики, графики
- 5. Делайте промежуточные выводы

Общие соображения

- 1. Один эксперимент --- одно изменение! Вы не представляете, насколько это важно. Пример: для эксперимента с моделью 1 Петя для получения эмбеддингов скачал предобученные веса ВЕКТ, а для эксперимента с моделью 2 -- предобученные веса RoBERTa. Вторая модель оказалась лучше, и Петя подумал, что архитектура второй модели лучше. Но, оказывается, с весами RoBERTa модель 1 работала бы не менее хорошо.
- 2. Всегда сравнивайте результаты эксперимента с результатами всех остальных экспериментов и делайте промежуточные выводы. Это самый важный пункт!
- 3. Не забывайте протестировать модель на адекватность. Для этого нужно задавать ей реальные вопросы и смотреть на ответы. Вопросы не должны быть элементами обучающей выборки!

git clone

```
In [ ]:
```

```
!git clone https://github.com/Alex-Norden/QA BoolQ.git
%cd QA_BoolQ
Cloning into 'QA BoolQ'...
remote: Enumerating objects: 19, done.
remote: Counting objects: 100% (19/19), done.
remote: Compressing objects: 100% (17/17), done.
remote: Total 19 (delta 1), reused 5 (delta 0), pack-reused 0
Unpacking objects: 100% (19/19), done.
/content/QA_BoolQ
```

Установка библиотек

```
In [ ]:
```

```
!pip -qq install fasttext
!pip -qq install transformers
                                       | 71kB 5.3MB/s eta 0:00:011
 Building wheel for fasttext (setup.py) ... done
                                        2.5MB 8.8MB/s
                                        901kB 36.6MB/s
```

3.3MB 43.5MB/s

Импорт библиотек

```
In [ ]:
import os
import random
import numpy as np
import pandas as pd
from tqdm import tqdm
import torch
import torch.nn as nn
from torch.utils.data import Dataset, DataLoader, random_split
from torch.optim import Adam
import torch.nn.functional as F
import matplotlib.pyplot as plt
from sklearn.metrics import accuracy_score, f1_score
import IPython
from collections import Counter
import warnings
warnings.filterwarnings('ignore')
DEVICE = torch.device('cuda' if torch.cuda.is_available() else 'cpu')
DEVICE
Out[3]:
device(type='cuda')
In [ ]:
import matplotlib.pyplot as plt
SEED = 42
def set_seed():
    np.random.seed(SEED)
    torch.random.manual_seed(SEED)
    torch.cuda.random.manual_seed(SEED)
    torch.cuda.random.manual_seed_all(SEED)
    torch.manual seed(SEED)
    torch.backends.cudnn.deterministic = True
def plot_training(train_losses, val_losses):
    """функция отрисовки графика обучения"""
    plt.figure(figsize=(12, 9))
    plt.subplot(2, 1, 1)
```

Часть 1. Эксплоративный анализ (1 балл)

plt.plot(train_losses, label='general train history')
plt.plot(val_losses, label='general valid history')

1. Посчитайте долю 'yes' и 'no' классов в корпусе

plt.xlabel('Epoch')

plt.legend()

- 2. Оцените среднюю длину вопроса
- 3. Оцените среднюю длину параграфа
- 4. Предположите, по каким эвристикам были собраны вопросы (или найдите ответ в статье). Продемонстрируйте, как эти эвристики повлияли на структуру корпуса.

In []:

```
train_file = "boolq/train.jsonl"
dev_file = "boolq/dev.jsonl"

df_train = pd.read_json(train_file, lines=True, orient="records")

df_dev = pd.read_json(dev_file, lines=True, orient="records")

def preproc(df):
    df.answer = df.answer.astype(int)

preproc(df_train)
preproc(df_dev)
```

```
In [ ]:
```

```
def describe(df, full=False):
   if full:
        print("isna:\n{}\n".format(df.isna().sum()))
   # посчитаем долю 'yes' и 'no' классов в корпусе
   total_count = len(df.answer)
   count_yes = df.answer.sum()
   count_no = total_count - count_yes
   percent_yes = 100.0 * count_yes / total_count
   percent no = 100.0 - percent yes
   print("'yes' количество: {}, доля: {:.2f} %".format(count_yes, percent_yes))
   print("'no' количество: {}, доля: {:.2f} %\n".format(count_no, percent_no))
   # оценим длины заголовка, вопроса, параграфа
   df_lens = df.copy()
   for col in ('title', 'question', 'passage'):
        new_col = "len_" + col
        df_lens[new_col] = df_lens[col].apply(lambda s: len(s))
   df_lens.drop(['title', 'question', 'answer', 'passage'], axis=1, inplace=True)
   print(df lens.describe())
   if full:
       # построим графики распределения длин
       def plot_distrib(col, title):
            lens = df_lens[col].values
            len num = pd.Series(Counter(lens))
            plt.figure(figsize=(12, 5))
            plt.bar(len_num.index, len_num.values)
            plt.title(title)
            plt.show()
            print()
        plot_distrib("len_title", "Распределение длин заголовка")
       plot_distrib("len_question", "Распределение длин вопроса")
        plot_distrib("len_passage", "Распределение длин параграфа")
```

In []:

max

78.000000

```
describe(df_train)
'yes' количество: 5874, доля: 62.31 %
'no' количество: 3553, доля: 37.69 %
         len title len question len passage
      9427.000000
                     9427.000000 9427.000000
count
         20.555002
                       43.991938
                                   565.613026
mean
std
         10.728475
                        8.854335
                                   323.137498
min
         1.000000
                       20.000000
                                    35.000000
         13.000000
25%
                       38.000000
                                   343.000000
50%
         18.000000
                       42.000000
                                   511.000000
75%
         26.000000
                       48.000000
                                   720.000000
```

100.000000 4720.000000

In []:

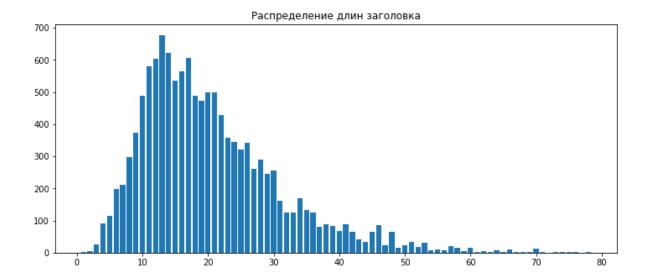
```
df = pd.concat([df_train, df_dev])
describe(df, full=True)
```

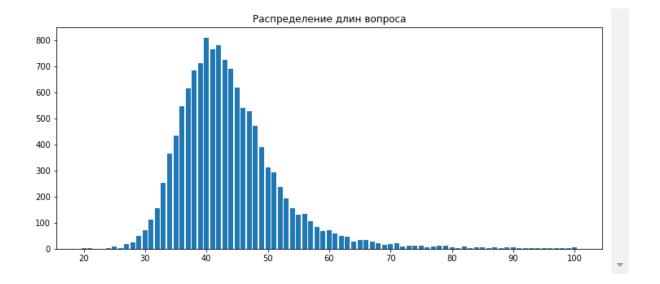
isna:
question 0
title 0
answer 0
passage 0

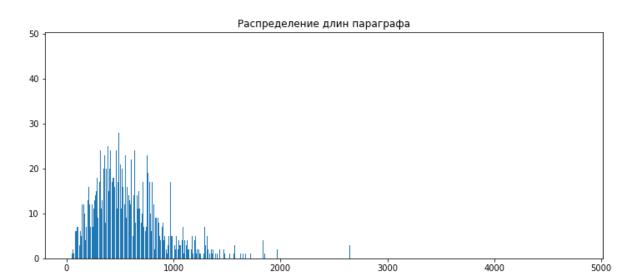
dtype: int64

'yes' количество: 7907, доля: 62.27 % 'no' количество: 4790, доля: 37.73 %

	len_title	len_question	len_passage
count	12697.000000	12697.000000	12697.000000
mean	20.477436	43.789635	563.923368
std	10.715538	8.598401	324.603916
min	1.000000	20.000000	35.000000
25%	13.000000	38.000000	343.000000
50%	18.000000	42.000000	508.000000
75%	26.000000	48.000000	715.000000
max	78.000000	100.000000	4781.000000



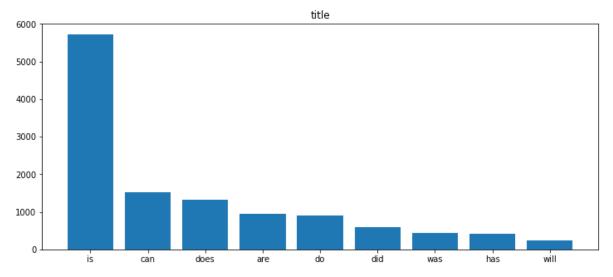




```
In [ ]:
```

```
df["sos"] = df["question"].apply(lambda s: s.split()[0])
words = df["sos"].values
word_num = pd.Series(Counter(words)).sort_values(ascending=False)[:9] #top 9

plt.figure(figsize=(12, 5))
plt.bar(word_num.index, word_num.values)
plt.title("title")
plt.show()
```



```
In [ ]:
```

```
print("Доля вопросов, начинающихся со служебных глаголов: {:.2f} %".format(100.0 * sum(word
```

Доля вопросов, начинающихся со служебных глаголов: 95.59 %

Как видно, более 95% всех вопросов начинаются со служебных глаголов. Такие вопросы подразумевают ответ да/нет.

Часть 2. Baseline (1 балл)

- 1. Оцените ассuracy точность совсем простого базового решения: присвоить каждой паре вопрос-ответ в dev части самый частый класс из train части
- 2. Оцените accuracy чуть более сложного базового решения: fasttext на текстах, состоящих из склеенных вопросов и абзацев (' '.join([question, passage]))

Почему fasttext плохо справляется с этой задачей?

Simple Baseline

```
In [ ]:
```

```
y_true = df_dev.answer.values
y_pred = [1]*len(y_true)
print("dev accuracy: {:.3f}".format(accuracy_score(y_true, y_pred)))
print("dev F1: {:.3f}".format(f1_score(y_true, y_pred)))

dev accuracy: 0.622
dev F1: 0.767
```

FastText

In []:

```
import fasttext
fasttext_train_path = 'fasttext_train.txt'
len_prefix = len('__label__')
def write_to_fasttext_dataset(df, res_file_path):
    inds = list(range(len(df)))
    random.shuffle(inds)
    with open(res_file_path, 'w') as fh:
        for i in inds:
            row = df.iloc[i]
            line = "__label__{{}} {} {} {}\n".format(row.answer, row.question, row.passage)
            fh.write(line)
write_to_fasttext_dataset(df_train, fasttext_train_path)
dev_input = [" ".join((row.question, row.passage)) for i, row in df_dev.iterrows()]
fasttext model = fasttext.train supervised(
    input=fasttext_train_path,
    dim=200, epoch=20, wordNgrams=2)
```

In []:

dev F1: 0.765

```
preds = fasttext_model.predict(dev_input, k=1)[0]
fasttext_preds = [int(s[0][len_prefix:]) for s in preds]
print("dev accuracy: {:.3f}".format(accuracy_score(y_true, fasttext_preds)))
print("dev F1: {:.3f}".format(f1_score(y_true, fasttext_preds)))
dev accuracy: 0.686
```

Из-за несбалансированности классов fasttext плохо справляется с задачей

Часть 3. Используем эмбеддинги предложений (2 балла)

1. Постройте BERT эмбеддинги вопроса и абзаца. Обучите логистическую регрессию на конкатенированных эмбеддингах вопроса и абзаца и оцените ассигасу этого решения.

[bonus] Используйте другие модели эмбеддингов, доступные, например, в библиотеке இ Transformers. Какая модель эмбеддингов даст лучшие результаты? [bonus] Предложите метод аугментации данных и продемонстрируйте его эффективность.

In []:

import logreg

DEVICE: cuda

```
In [ ]:
logreg.run_model("distilbert-base-uncased", grid_search=True)
# Logreg.run_model("distilbert-base-uncased", max_length=512)
HBox(children=(FloatProgress(value=0.0, description='Downloading', max=23150
8.0, style=ProgressStyle(descripti...
HBox(children=(FloatProgress(value=0.0, description='Downloading', max=28.0,
style=ProgressStyle(description_w...
HBox(children=(FloatProgress(value=0.0, description='Downloading', max=46606
2.0, style=ProgressStyle(descripti...
HBox(children=(FloatProgress(value=0.0, description='Downloading', max=442.0,
style=ProgressStyle(description_...
HBox(children=(FloatProgress(value=0.0, description='Downloading', max=267967
963.0, style=ProgressStyle(descri...
Some weights of the model checkpoint at distilbert-base-uncased were not used
when initializing DistilBertModel: ['vocab_transform.weight', 'vocab_projecto
r.weight', 'vocab_layer_norm.bias', 'vocab_transform.bias', 'vocab_layer_nor
m.weight', 'vocab_projector.bias']
- This IS expected if you are initializing DistilBertModel from the checkpoin
t of a model trained on another task or with another architecture (e.g. initi
alizing a BertForSequenceClassification model from a BertForPreTraining mode
1).
- This IS NOT expected if you are initializing DistilBertModel from the check
point of a model that you expect to be exactly identical (initializing a Bert
ForSequenceClassification model from a BertForSequenceClassification model).
Truncation was not explicitly activated but `max_length` is provided a specif
ic value, please use `truncation=True` to explicitly truncate examples to max
```

```
length. Defaulting to 'longest_first' truncation strategy. If you encode pair
s of sequences (GLUE-style) with the tokenizer you can select this strategy m
ore precisely by providing a specific strategy to `truncation`.
```

```
embeddings...
training...
grid search...
Fitting 5 folds for each of 12 candidates, totalling 60 fits
[Parallel(n_jobs=-1)]: Using backend LokyBackend with 2 concurrent worker
s.
[Parallel(n_jobs=-1)]: Done
                              1 tasks
                                           | elapsed:
                                                         0.9s
[Parallel(n_jobs=-1)]: Done
                              4 tasks
                                           | elapsed:
                                                         1.0s
[Parallel(n_jobs=-1)]: Done
                              9 tasks
                                           | elapsed:
                                                         3.9s
[Parallel(n_jobs=-1)]: Done 14 tasks
                                           | elapsed:
                                                         4.0s
[Parallel(n_jobs=-1)]: Done
                             21 tasks
                                           elapsed:
                                                        12.5s
[Parallel(n_jobs=-1)]: Done
                             28 tasks
                                           | elapsed:
                                                        27.3s
[Parallel(n_jobs=-1)]: Done 37 tasks
                                           | elapsed: 1.0min
[Parallel(n_jobs=-1)]: Done 46 tasks
                                           elapsed:
                                                       1.7min
```

```
[Parallel(n_jobs=-1)]: Done 57 tasks
                                           | elapsed: 3.2min
best_params: {'C': 0.1, 'penalty': '12'}
best_score: 0.6867459347782082
best_estimator: LogisticRegression(C=0.1, class_weight=None, dual=False, fit_
intercept=True,
                   intercept_scaling=1, l1_ratio=None, max_iter=1000,
                   multi_class='auto', n_jobs=None, penalty='12',
                   random_state=42, solver='lbfgs', tol=0.0001, verbose=0,
                   warm_start=False)
prediction...
Test Acc: 0.676 | Test F1: 0.764
```

Out[15]:

(0.6758409785932722, 0.764129951045839)

```
In [ ]:
```

```
logreg.run_model("bert-base-uncased")
# logreg.run_model("bert-base-uncased", max_length=512)
```

HBox(children=(FloatProgress(value=0.0, description='Downloading', max=23150
8.0, style=ProgressStyle(descripti...

HBox(children=(FloatProgress(value=0.0, description='Downloading', max=28.0, style=ProgressStyle(description_w...

HBox(children=(FloatProgress(value=0.0, description='Downloading', max=46606
2.0, style=ProgressStyle(descripti...

HBox(children=(FloatProgress(value=0.0, description='Downloading', max=570.0,
style=ProgressStyle(description_...

HBox(children=(FloatProgress(value=0.0, description='Downloading', max=440473 133.0, style=ProgressStyle(descri...

Some weights of the model checkpoint at bert-base-uncased were not used when initializing BertModel: ['cls.predictions.transform.LayerNorm.weight', 'cls.p redictions.transform.dense.bias', 'cls.predictions.decoder.weight', 'cls.seq_relationship.weight', 'cls.seq_relationship.bias', 'cls.predictions.transform.LayerNorm.bias', 'cls.predictions.transform.dense.weight', 'cls.prediction s.bias']

- This IS expected if you are initializing BertModel from the checkpoint of a model trained on another task or with another architecture (e.g. initializing a BertForSequenceClassification model from a BertForPreTraining model).
- This IS NOT expected if you are initializing BertModel from the checkpoint of a model that you expect to be exactly identical (initializing a BertForSeq uenceClassification model from a BertForSequenceClassification model). Truncation was not explicitly activated but `max_length` is provided a specific value, please use `truncation=True` to explicitly truncate examples to max length. Defaulting to 'longest_first' truncation strategy. If you encode pair

ic value, please use `truncation=True` to explicitly truncate examples to max length. Defaulting to 'longest_first' truncation strategy. If you encode pair s of sequences (GLUE-style) with the tokenizer you can select this strategy m ore precisely by providing a specific strategy to `truncation`.

```
embeddings...
training...
prediction...
Test Acc: 0.678 | Test F1: 0.763
Out[16]:
(0.6782874617737003, 0.763063063063063)
```

```
In [ ]:
```

```
logreg.run_model("roberta-base")
# logreg.run_model("roberta-base", max_length=512)
HBox(children=(FloatProgress(value=0.0, description='Downloading', max=89882
3.0, style=ProgressStyle(descripti...
HBox(children=(FloatProgress(value=0.0, description='Downloading', max=45631
8.0, style=ProgressStyle(descripti...
HBox(children=(FloatProgress(value=0.0, description='Downloading', max=135586
3.0, style=ProgressStyle(descript...
HBox(children=(FloatProgress(value=0.0, description='Downloading', max=481.0,
style=ProgressStyle(description_...
HBox(children=(FloatProgress(value=0.0, description='Downloading', max=501200
538.0, style=ProgressStyle(descri...
Some weights of the model checkpoint at roberta-base were not used when initi
alizing RobertaModel: ['lm_head.decoder.weight', 'lm_head.bias', 'lm_head.lay
er_norm.weight', 'lm_head.dense.weight', 'lm_head.dense.bias', 'lm_head.layer
_norm.bias']
- This IS expected if you are initializing RobertaModel from the checkpoint o
f a model trained on another task or with another architecture (e.g. initiali
zing a BertForSequenceClassification model from a BertForPreTraining model).
- This IS NOT expected if you are initializing RobertaModel from the checkpoi
nt of a model that you expect to be exactly identical (initializing a BertFor
SequenceClassification model from a BertForSequenceClassification model).
Truncation was not explicitly activated but `max length` is provided a specif
ic value, please use `truncation=True` to explicitly truncate examples to max
length. Defaulting to 'longest_first' truncation strategy. If you encode pair
s of sequences (GLUE-style) with the tokenizer you can select this strategy m
ore precisely by providing a specific strategy to `truncation`.
embeddings...
training...
prediction...
Test Acc: 0.651 | Test F1: 0.755
Out[17]:
(0.6507645259938838, 0.755040755040755)
```

Часть 4. Обучаем BERT на конкатенации вопроса и предложения (2 балла)

В этой части предлагается реализовать фреймворк, описанный в <u>видео по ссылке</u> (https://www.youtube.com/watch?v=l8ZYCvgGu0o), адаптировав его под бинарный Question Answering.

1. Опишите модель, которую вы будете реализовывать. Загрузите предобученный BERT, добавьте полносвязные "головные" слои. Дообучите модель: попробуйте разные способы обучения.

[bonus] Используйте модель <u>RoBERTa (https://arxiv.org/abs/1907.11692)</u> вместо модели BERT. Посмотрите, что получилось.

In [27]:

```
import seq_clf

# For reloading
import imp
imp.reload(seq_clf)
```

```
DEVICE: cuda
Out[27]:
<module 'seq_clf' from '/content/QA_BoolQ/seq_clf.py'>
```

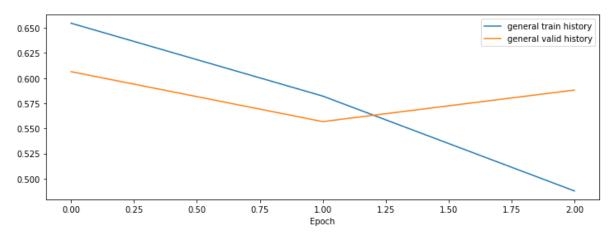
```
history = seq_clf.run_model("bert-base-uncased")
plot_training(*history)
```

Some weights of the model checkpoint at bert-base-uncased were not used when initializing BertForSequenceClassification: ['cls.predictions.transform.Layer Norm.weight', 'cls.predictions.transform.dense.bias', 'cls.predictions.decode r.weight', 'cls.seq_relationship.weight', 'cls.seq_relationship.bias', 'cls.predictions.transform.LayerNorm.bias', 'cls.predictions.transform.dense.weigh t', 'cls.predictions.bias']

- This IS expected if you are initializing BertForSequenceClassification from the checkpoint of a model trained on another task or with another architecture (e.g. initializing a BertForSequenceClassification model from a BertForPreT raining model).
- This IS NOT expected if you are initializing BertForSequenceClassification from the checkpoint of a model that you expect to be exactly identical (initializing a BertForSequenceClassification model from a BertForSequenceClassification model).

Some weights of BertForSequenceClassification were not initialized from the model checkpoint at bert-base-uncased and are newly initialized: ['classifier.bias', 'classifier.weight']

You should probably TRAIN this model on a down-stream task to be able to use it for predictions and inference.



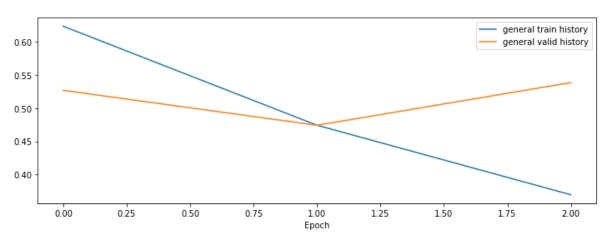
```
history = seq_clf.run_model("roberta-base", batch_size=8, use_segment_ids=False)
plot_training(*history)
```

Some weights of the model checkpoint at roberta-base were not used when initi alizing RobertaForSequenceClassification: ['lm_head.decoder.weight', 'lm_head.desoder.weight', 'lm_head.dense.weight', 'roberta.poole r.dense.weight', 'lm_head.dense.bias', 'lm_head.layer_norm.bias', 'roberta.po oler.dense.bias']

- This IS expected if you are initializing RobertaForSequenceClassification f rom the checkpoint of a model trained on another task or with another archite cture (e.g. initializing a BertForSequenceClassification model from a BertForPreTraining model).
- This IS NOT expected if you are initializing RobertaForSequenceClassificati on from the checkpoint of a model that you expect to be exactly identical (in itializing a BertForSequenceClassification model from a BertForSequenceClassification model).

Some weights of RobertaForSequenceClassification were not initialized from the model checkpoint at roberta-base and are newly initialized: ['classifier.de nse.weight', 'classifier.out_proj.bias', 'classifier.out_proj.weight', 'classifier.dense.bias']

You should probably TRAIN this model on a down-stream task to be able to use it for predictions and inference.



In [21]:

```
history = seq_clf.run_model("roberta-large", batch_size=8, use_segment_ids=False)
plot_training(*history)
```

HBox(children=(FloatProgress(value=0.0, description='Downloading', max=482.0, style=ProgressStyle(description_...

HBox(children=(FloatProgress(value=0.0, description='Downloading', max=89882
3.0, style=ProgressStyle(descripti...

HBox(children=(FloatProgress(value=0.0, description='Downloading', max=45631
8.0, style=ProgressStyle(descripti...

HBox(children=(FloatProgress(value=0.0, description='Downloading', max=135586 3.0, style=ProgressStyle(descript...

HBox(children=(FloatProgress(value=0.0, description='Downloading', max=142594 1629.0, style=ProgressStyle(descr...

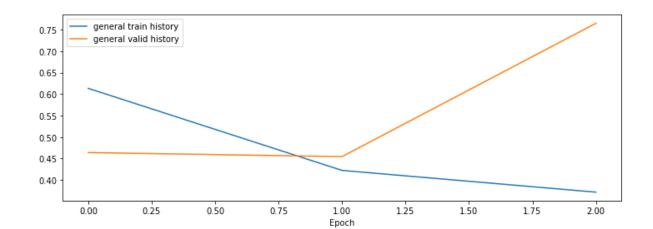
Some weights of the model checkpoint at roberta-large were not used when init ializing RobertaForSequenceClassification: ['lm_head.decoder.weight', 'lm_head.decoder.weight', 'lm_head.dense.weight', 'roberta.poole r.dense.weight', 'lm_head.dense.bias', 'lm_head.layer_norm.bias', 'roberta.po oler.dense.bias']

- This IS expected if you are initializing RobertaForSequenceClassification f rom the checkpoint of a model trained on another task or with another archite cture (e.g. initializing a BertForSequenceClassification model from a BertForPreTraining model).
- This IS NOT expected if you are initializing RobertaForSequenceClassificati on from the checkpoint of a model that you expect to be exactly identical (in itializing a BertForSequenceClassification model from a BertForSequenceClassification model).

Some weights of RobertaForSequenceClassification were not initialized from the model checkpoint at roberta-large and are newly initialized: ['classifier.d ense.weight', 'classifier.out_proj.bias', 'classifier.out_proj.weight', 'classifier.dense.bias']

You should probably TRAIN this model on a down-stream task to be able to use it for predictions and inference.

Test Loss: 0.439 | Test Acc: 0.821 | Test F1: 0.861



Большая модель показала ещё лучшее качество. Попробуем ещё дообучить её.

In []:

```
full_history = list(history)
```

```
history = seq_clf.run_model("roberta-large", batch_size=8, use_segment_ids=False, load_stat
```

Some weights of the model checkpoint at roberta-large were not used when init ializing RobertaForSequenceClassification: ['lm_head.decoder.weight', 'lm_head.decoder.weight', 'lm_head.dense.weight', 'roberta.poole r.dense.weight', 'lm_head.dense.bias', 'lm_head.layer_norm.bias', 'roberta.po oler.dense.bias']

- This IS expected if you are initializing RobertaForSequenceClassification f rom the checkpoint of a model trained on another task or with another archite cture (e.g. initializing a BertForSequenceClassification model from a BertForPreTraining model).
- This IS NOT expected if you are initializing RobertaForSequenceClassificati on from the checkpoint of a model that you expect to be exactly identical (in itializing a BertForSequenceClassification model from a BertForSequenceClassification model).

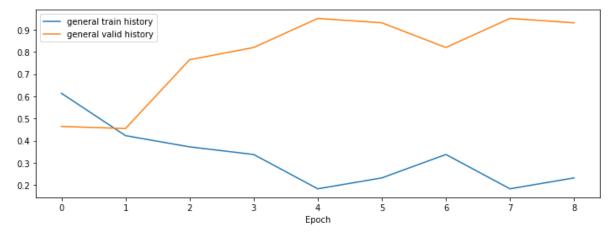
Some weights of RobertaForSequenceClassification were not initialized from the model checkpoint at roberta-large and are newly initialized: ['classifier.d ense.weight', 'classifier.out_proj.bias', 'classifier.out_proj.weight', 'classifier.dense.bias']

You should probably TRAIN this model on a down-stream task to be able to use it for predictions and inference.

loading state...

In [34]:

```
full_history[0].extend(history[0])
full_history[1].extend(history[1])
plot_training(*full_history)
```



Видим переобучение, но на тесте удалось увеличить ассuracy и f1-score.

Часть 5. BiDAF-подобная архитектура (2 балла)

Архитектура BiDAF является специфической архитектурой для QA. Здесь вам предлагается её реализовать.

Основана на статье: Bidirectional Attention Flow for Machine Comprehension

Minjoon Seo, Aniruddha Kembhavi, Ali Farhadi, Hannaneh Hajishirzi

https://arxiv.org/abs/1611.01603 (https://arxiv.org/abs/1611.01603)

Архитектура BiDAF предложена для задачи SQuAD, но легко может быть адаптирована к текущему заданию. Модель состоит из следующих блоков:

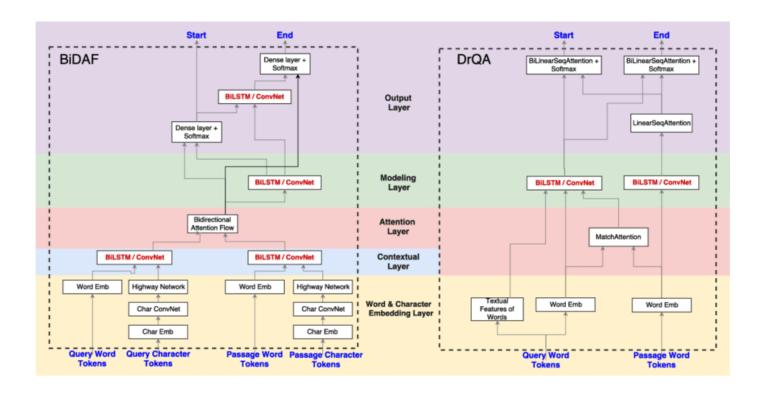
- 1. Кодировщик получает на вход два представления слова: эмбеддинг слова и полученное из CNN посимвольное представление слова. Кодировщики для вопроса и для параграфа одинаковы.
- 2. Слой внимания (детальное описание приведено в статье, см. пункт Attention Flow Layer)
- 3. Промежуточный слой, который получает на вход контекстуализированные эмбеддинги слов из параграфа, состоящие из трех частей (выход кодировщика параграфа, Query2Context (один вектор) и Context2Query (матрица) выравнивания
- 4. Слой предсказания.

Предложите, как можно было модифицировать последний слой предсказания в архитектуре BiDAF, с учетом того, что итоговое предсказание – это метка yes / no, предсказание которой проще, чем предсказание спана ответа для SQuAD.

Оцените качество этой модели для решения задачи.

[bonus] Замените входные эмбеддинги и все дополнительные признаки, используемые кодировщиками, на BERT или RoBERTa эмбеддинги. Улучшит ли это качество результатов?

Сравнение DrQA и BiDAF:



In [35]:

building vocab...
building iterators...

```
import bidaf
from bidaf import Loader, BiDAF
from torchtext.vocab import GloVe
vectors = GloVe(name="6B", dim=300)
loader = Loader(32, 64, vectors, DEVICE)
config = dict(
    pretrained=loader.WORD.vocab.vectors,
    char_vocab_size=len(loader.CHAR.vocab),
    char_emb_dim=15,
    char_hidden_size=15,
    char_kernel_size=5,
    emb_dim=300,
    hidden_size=100,
    dropout=0.2)
set_seed()
model = BiDAF(**config).to(DEVICE)
[nltk_data] Downloading package punkt to /root/nltk_data...
             Unzipping tokenizers/punkt.zip.
.vector_cache/glove.6B.zip: 0.00B [00:00, ?B/s]
DEVICE: cuda
.vector_cache/glove.6B.zip: 862MB [02:46, 5.17MB/s]
          | 399442/400000 [00:37<00:00, 10266.68it/s]
building splits...
```

399442/400000 [00:49<00:00, 10266.68it/s]

```
In [36]:
n epochs = 10
clip = 3
# optimizer = torch.optim.Adadelta(model.parameters(), lr=0.5)
optimizer = torch.optim.Adam(model.parameters())
criterion = nn.BCEWithLogitsLoss()
history = bidaf.train_loop(
    model,
    optimizer,
    criterion,
    loader.train_iter,
    loader.val_iter,
    n_epochs,
    clip)
plot_training(*history)
Epoch: 01
        Train Loss: 0.653
         Val. Loss: 0.653 | Val. Acc: 0.624 | Val. F1: 0.744
Epoch: 02
        Train Loss: 0.611
         Val. Loss: 0.654 | Val. Acc: 0.628 | Val. F1: 0.713
Epoch: 03
        Train Loss: 0.559
         Val. Loss: 0.656 | Val. Acc: 0.631 | Val. F1: 0.701
Epoch: 04
        Train Loss: 0.482
         Val. Loss: 0.668 | Val. Acc: 0.657 | Val. F1: 0.768
Epoch: 05
```

Val. Loss: 0.693 | Val. Acc: 0.643 | Val. F1: 0.726

Val. Loss: 0.857 | Val. Acc: 0.671 | Val. F1: 0.748

Val. Loss: 1.096 | Val. Acc: 0.647 | Val. F1: 0.727

Val. Loss: 1.200 | Val. Acc: 0.660 | Val. F1: 0.730

Val. Loss: 1.403 | Val. Acc: 0.648 | Val. F1: 0.712

Val. Loss: 1.396 | Val. Acc: 0.653 | Val. F1: 0.725

Train Loss: 0.378

Train Loss: 0.269

Train Loss: 0.184

Train Loss: 0.134

Train Loss: 0.093

Train Loss: 0.077

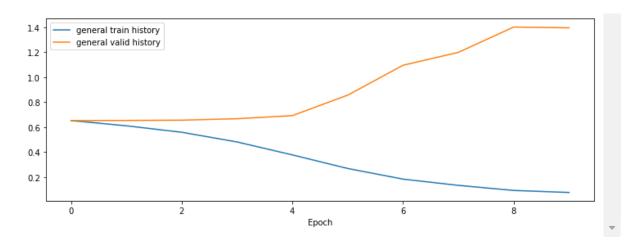
Epoch: 06

Epoch: 07

Epoch: 08

Epoch: 09

Epoch: 10



In [37]:

```
bidaf.test(model, criterion, loader.test_iter, to_print=True)
```

Test Loss: 1.389 | Test Acc: 0.662 | Test F1: 0.731

Out[37]:

(1.3894592294326196, 0.6620795107033639, 0.7313396547532214)

In [38]:

```
best_model = BiDAF(**config).to(DEVICE)
best_model.load_state_dict(torch.load(bidaf.BEST_MODEL_PATH))
```

Out[38]:

<All keys matched successfully>

In [39]:

```
bidaf.test(best_model, criterion, loader.test_iter, to_print=True)
```

Test Loss: 0.878 | Test Acc: 0.657 | Test F1: 0.740

Out[39]:

(0.8779690999251145, 0.6565749235474007, 0.7401064568386948)

Часть 6. Итоги (2 балла)

Напишите краткое резюме проделанной работы. Сравните результаты всех разработанных моделей. Что помогло вам в выполнении работы, чего не хватало?

Simple Baseline

Ассигасу простого базового решения на тесте составляет 62.2%, f1-score 76.7%.

FastText

Чуть более сложное решение с использованием FastText позволяет повысить ассuracy до 68.6%, f1-score составляет 76.5%.

LogisticRegression (Transformers-эмбеддинги)

Для получения эмбеддингов использовались DistilBERT, BERT, RoBERTa. Лучше других с задачей справился BERT, который лишь немного обошёл DistilBERT'a.

С логистической регрессией на конкатенированных эмбеддингах вопроса и абзаца удалось получить на тесте accuracy 67.8% и f1-score 76.3%. Немного хуже подхода с FastText.

Transformers for Sequence Classification

BERT-base, обученный на конкатенированных вопросах и параграфах, превзошёл по качеству предыдущие модели.

RoBERTa-base улучшила качество, а 'её старшая сестра' RoBERTa-large ещё улучшила и показала на тесте accuracy 84% и f1-score 87.3%.

BiDAF

В качестве входных эмбеддингов использовал GloVe. Модель довольно быстро переобучается. Удалось получить на тесте accuracy 66.2% и f1-score 73.1%.

Дополнительные ресурсы:

In []:

```
https://drive.google.com/drive/folders/1f087dcVFr9yPBFE1CgGu_pBY45pt-yr8
https://github.com/pytorch/examples
https://github.com/huggingface/transformers
https://arxiv.org/abs/1810.04805
https://arxiv.org/abs/1907.11692
https://colab.research.google.com/drive/1T94TTX_3kVYrEnzKrGFKrJ3y5WfJJ4zq
https://colab.research.google.com/drive/1uSlWtJdZmLrI3FCNIlUHFxwAJiSu2J0-
https://github.com/allenai/bi-att-flow
https://torchtext.readthedocs.io/en/latest/
https://github.com/galsang/BiDAF-pytorch
https://github.com/svinkapeppa/MIPT_NLP_2020
https://towardsdatascience.com/the-definitive-guide-to-bi-directional-attention-flow-d0e96e
```